

windows+docker desktop部署HF TEI (GPU)

参考：

https://huggingface.co/docs/text-embeddings-inference/en/quick_tour#deploy

GPU环境适配

CUDA版本需要在12.2及以上

检查cuda版本

```
1  nvidia-smi
```

选择性安装NVIDIA Container Toolkit: <https://docs.nvidia.com/datacenter/cloud-native/container-toolkit/latest/install-guide.html>

通常来说：The NVIDIA Container Toolkit is included with Docker Desktop for Windows and Docker Desktop for Mac. 无需额外安装。

可以创建跑一个sample CUDA container来检查驱动和toolkit是否安装到位（测试后可自行清理image）

代码块

```
1  docker run --rm --runtime=nvidia --gpus all ubuntu nvidia-smi
```

- Run a sample CUDA container:



```
sudo docker run --rm --runtime=nvidia --gpus all ubuntu nvidia-smi
```

Your output should resemble the following output:

+-----+										
NVIDIA-SMI 535.86.10			Driver Version: 535.86.10				CUDA Version: 12.2			
+-----+										
GPU Name		Persistence-M		Bus-Id		Disp.A		Volatile Uncorr. ECC		
Fan	Temp	Perf	Pwr:Usage/Cap		Memory-Usage			GPU-Util	Compute M.	
=====										
0	Tesla T4		On	00000000:00:1E.0	Off			0%	Default	
N/A	34C	P8	9W / 70W	0MiB / 15109MiB					N/A	
+-----+										
Processes:										
GPU	GI	CI	PID	Type	Process name	GPU Memory				
	ID	ID				Usage				
=====										
No running processes found										

部署GPU HF TEI

建议一个模型对应一个container与端口。例如用模型名称作为端口名称，并设置专属port。

代码块

```
1  # 保存模型文件的目录
2  cd E:\MODELS
3
4  # 模型选择 (参考hugging face)
5  $model = "BAAI/bge-m3"
6  # 模型保存本地文件位置
7  $volume = "$PWD\data"
8  # 端口名称 (唯一)
9  $my_port = 8080
10 # 容器名称 (唯一)
11 $my_container = "tei-bge-m3"
12
13 # 启动容器
14 docker run -d --gpus all -p "${my_port}:80" -v "$volume`:/data" --pull always -
    -name $my_container ghcr.io/huggingface/text-embeddings-inference:1.8 --model-
    id $model
```

记住port (-p): 此处为<http://localhost:8080>

- 需要替换模型时，直接替换

```
$model = "Alibaba-NLP/gte-multilingual-base"
```

```
$my_port = 8080
```

```
$my_container = "tei-gte-multilingual"
```

创建一个新的container。

可在docker desktop交互管理各个container。